

## Índice

As páginas são indicadas no rodapé do PDF. Abaixo, a estrutura do documento:

### 1. Introdução

- 1.1 Contexto
- 1.2 Definição do Problema
- 1.3 Questões de Pesquisa e Hipóteses
- 1.4 Objetivo Principal

### 2. Planejamento e execução do experimento

- 2.1 Evidência visual do planejamento — Parte 2

### 3. Metodologia

- 3.1 Criação do Dataset
- 3.2 Teste Estatístico
- 3.3 Sumarização dos Resultados

### 4. Resultados (RQs)

- RQ01 — Status de aceite vs. Tamanho do PR
- RQ02 — Status de aceite vs. Tempo de análise
- RQ03 — Status de aceite vs. Descrição
- RQ04 — Status de aceite vs. Interações
- RQ05 — Revisões vs. Tamanho do PR
- RQ06 — Revisões vs. Tempo de análise
- RQ07 — Revisões vs. Descrição
- RQ08 — Revisões vs. Interações

### 5. Sumarização global das métricas (processo)

- 5.1 Interpretação (processo)

### 6. Discussão Geral e Conclusão

## 1. Introdução

A revisão de código (code review) é uma etapa indispensável no desenvolvimento de software, destacando-se em metodologias ágeis e projetos de código aberto (open source). Seu propósito é auditar modificações antes de incorporá-las à base principal do projeto, minimizando a inserção de falhas e elevando a qualidade do produto final. No ecossistema do GitHub, essa dinâmica ocorre primordialmente através de Pull Requests (PRs). Neles, as submissões são debatidas e julgadas por revisores, resultando em sua integração (MERGED) ou rejeição (CLOSED), frequentemente com o auxílio de checagens automatizadas. O presente laboratório tem como finalidade realizar uma caracterização empírica dessa prática em repositórios de destaque no GitHub. Para isso, investiga-se de que maneira fatores como tamanho da alteração, tempo de duração, riqueza da descrição e nível de interação afetam o desfecho do PR e a quantidade de revisões exigidas, evidenciando o impacto dessas variáveis no esforço analítico e na chance de aprovação.

### 1.1 Contexto

No GitHub, o PR atua como a unidade central para a análise de code review, pois congrega tanto as alterações técnicas quanto o histórico social do processo. Ele funciona, por um lado, como um "pacote de código" que deve ser validado quanto à sua exatidão e compatibilidade. Por outro, age como um fórum de negociação que registra comentários, exigências de correção, aprovações e o diálogo entre os envolvidos com diferentes atribuições.

A teoria e a prática indicam que os atributos do PR impactam diretamente a carga de trabalho da revisão e as chances de aceitação. Modificações extensas costumam exigir mais tempo de leitura e aumentam o risco de erros passarem despercebidos, enquanto envios menores tendem a ser assimilados rapidamente. O intervalo entre a abertura e o fechamento de um PR pode revelar tanto a sua complexidade técnica quanto a necessidade de muito retrabalho. Além disso, a qualidade da descrição dita o ritmo da revisão, pois esclarece motivações, limites, riscos e métodos de teste, facilitando ou travando o trabalho do revisor. Por fim, o volume de interações (como o número de participantes e comentários) aponta para processos mais colaborativos, rigorosos ou polêmicos, influenciando o sucesso da integração.

Como os repositórios populares variam drasticamente em termos de linguagem, governança, políticas de aceite e nível de automação, é crucial validar essas hipóteses intuitivas de forma empírica e em larga escala. Dessa forma, caracterizar o code review através de dados extraídos de PRs possibilita a identificação objetiva de padrões, gerando insights valiosos para colaboradores e mantenedores de projetos.

### 1.2 Definição do Problema

O foco deste experimento é investigar a relação entre as características observáveis dos PRs revisados e o desfecho do processo de revisão. De forma específica, analisa-se como as variáveis de tamanho, duração da análise, detalhamento da descrição e engajamento social determinam se um PR será efetivamente incorporado (MERGED) ou encerrado sem aprovação (CLOSED).

Para além do status final, o estudo também mede o impacto dessas mesmas características na intensidade da revisão, utilizando o total de revisões executadas no PR como métrica. Para garantir que os dados reflitam predominantemente o esforço humano — e para mitigar o viés de encerramentos automatizados —, o conjunto de dados foi filtrado para incluir exclusivamente PRs que possuam ao menos uma avaliação registrada e cujo tempo de vida (da abertura ao desfecho) ultrapasse uma hora.

### 1.3 Questões de Pesquisa e Hipóteses

Abaixo estão as perguntas que norteiam a pesquisa e as hipóteses informais elaboradas a partir das expectativas do comportamento em repositórios populares no GitHub.

- RQ01 (Tamanho vs Status): Estima-se que PRs com um volume massivo de modificações tenham menores chances de aprovação (MERGED). Alterações muito grandes sobrecarregam o revisor cognitivamente, elevam a probabilidade de falhas e complicam a análise de impacto, o que geralmente resulta em mais exigências de refatoração ou descarte.
- RQ02 (Tempo vs Status): PRs que demoram longos períodos em análise tendem a ser finalizados como CLOSED. Prazos extensos indicam atritos no processo, fazendo com que o código fique obsoleto frente à branch principal (envelhecimento do PR).
- RQ03 (Descrição vs Status): Textos descritivos mais robustos (maior body length) aumentam a probabilidade de um PR ser MERGED. Explicações minuciosas clarificam a intenção da mudança e métodos de teste, mitigando as dúvidas dos revisores.
- RQ04 (Interações vs Status): PRs com altos índices de comentários e participantes tendem a ser CLOSED. O alto engajamento frequentemente sinaliza polêmicas, identificação de falhas ou longos debates sobre arquitetura e estilo, gerando um desgaste que pode culminar na rejeição.

# Laboratório 03 — Caracterizando a Atividade de Code Review no GitHub

## Relatório Final · Lab03S03 · Análise, Visualização e Síntese

Engenharia de Software · Laboratório de Experimentação de Software · 6º Período · PUC Minas

Gerado em: 15/05/2026

Professor: Danilo de Quadros Maia Filho

Alunos: Sthel Felipe Torres e Vinicius Xavier Ramalho

- RQ05 (Tamanho vs Revisões): Existe uma correlação positiva entre o tamanho do PR e a quantidade de revisões. Submissões extensas naturalmente demandam inspeções mais longas e são mais suscetíveis a apontamentos em diferentes módulos do código.
- RQ06 (Tempo vs Revisões): Quanto mais revisões um PR sofre, maior o seu tempo total de tramitação. Cada novo ciclo exige leitura, debate, codificação de correções e reexecução de testes automatizados (CI), alongando o período.
- RQ07 (Descrição vs Revisões): Antecipa-se uma correlação negativa, em que descrições mais ricas resultam em menos revisões. Quando a motivação e a lógica da mudança são bem expostas desde o princípio, o revisor tem menos dúvidas estruturais, encurtando rodadas de feedback.
- RQ08 (Interações vs Revisões): Prevê-se uma associação positiva entre as métricas de interação e a quantidade de revisões. Conversas e discussões densas geralmente geram a necessidade de ajustes complementares. Assim, o feedback resulta em novas validações formais.

### 1.4 Objetivo Principal

Realizar uma caracterização empírica da dinâmica de code review em repositórios de grande circulação no GitHub. O intuito é mapear como as métricas relativas a tamanho, duração temporal, qualidade do texto descritivo e engajamento social estão atreladas ao desfecho do processo e à quantidade de revisões recebidas. O fim último da pesquisa é extrair evidências quantitativas consistentes através da modelagem estatística de 10.333 PRs.


## 2. Planejamento e execução do experimento

As figuras abaixo documentam o planejamento experimental (desenho inicial, etapas e organização da análise).

### Etapa 1: Coleta de Repositórios



### Etapa 2: Coleta de Pull Requests



# Laboratório 03 — Caracterizando a Atividade de Code Review no GitHub

## Relatório Final · Lab03S03 · Análise, Visualização e Síntese

Engenharia de Software · Laboratório de Experimentação de Software · 6º Período · PUC Minas


Gerado em: 15/05/2026

Professor: Danilo de Quadros Maia Filho


Alunos: StHEL Felipe Torres e Vinicius Xavier Ramalho

### 2.1 Evidência visual do planejamento — Parte 2

#### Etapa 3: Extração de Métricas



#### Etapa 4: Análise e Síntese



### 3. Metodologia

#### 3.1 Criação do Dataset

Os dados foram coletados via API GraphQL do GitHub. O dataset é composto pelos 10333 PRs que satisfazem todos os critérios abaixo:

- Repositórios: 200 repositórios mais populares do GitHub (ordenados por número de estrelas).
- Requisito mínimo por repositório: pelo menos 100 PRs com status MERGED ou CLOSED.
- Status do PR: apenas MERGED ou CLOSED (PRs abertos foram excluídos).
- Revisões: apenas PRs com pelo menos uma revisão registrada (campo `reviews.totalCount`  $\geq 1$ ).
- Filtro anti-bot: apenas PRs cujo intervalo entre a criação e o fechamento/merge é superior a 1 hora — eliminando revisões automáticas realizadas por bots ou ferramentas de CI/CD.

#### 3.2 Teste Estatístico

Utilizamos o coeficiente de correlação de Spearman para todas as análises. A escolha é justificada pela natureza não-paramétrica dos dados: as métricas coletadas (linhas de código, tempo de análise, número de comentários) apresentam assimetria severa e outliers extremos, tornando a distribuição normal inviável e o teste de Pearson inadequado. O Spearman opera sobre postos (ranks), sendo robusto a essas distorções. Para cada correlação, calculamos também o p-valor (aproximação t-Student bilateral) com limiar de significância  $\alpha = 0,05$ .

#### 3.3 Sumarização dos Resultados


Conforme indicado no enunciado, as análises utilizam os valores medianos calculados sobre todos os PRs do dataset — sem divisão por repositório. Para a Dimensão A (Status do PR), a variável dependente é binária: MERGED = 1, CLOSED = 0. Para a Dimensão B (Número de Revisões), a variável dependente é o campo `reviews_count`.

### 4. Resultados (RQs)

RQ01 — Status de aceite vs. Tamanho do PR

Hipótese: PRs menores (menos arquivos/linhas) têm maior chance de serem aceitos (MERGED).

| Métrica                              | Mediana MERGED | Mediana CLOSED |
|--------------------------------------|----------------|----------------|
| Arquivos Alterados                   | 2,00           | 1,00           |
| Total de Linhas (adições + remoções) | 34,00          | 28,00          |



Correlação [Arquivos Alterados]: fraca positiva ( $\rho = 0,100$ ,  $p < 0,001$ )

↳ [Total de Linhas (adições + remoções)]: sem correlação ( $\rho = 0,030$ ,  $p = 2,321e-003$ )


Discussão: Hipótese refutada: O coeficiente é positivo indicando que PRs maiores tendem a ser aceitos.

RQ02 — Status de aceite vs. Tempo de análise

Hipótese: PRs que levam mais tempo em análise tendem a ser rejeitados (CLOSED).

| Métrica                  | Mediana MERGED | Mediana CLOSED |
|--------------------------|----------------|----------------|
| Tempo de Análise (Horas) | 13,04          | 38,93          |

Status de aceite vs. Tempo de análise



Correlação [Tempo de Análise (Horas)]: fraca negativa ( $\rho = -0,139$ ,  $p < 0,001$ )

Discussão: Hipótese confirmada: Tempo longo se correlaciona com rejeição (coeficiente negativo).




RQ03 — Status de aceite vs. Descrição

Hipótese: PRs com descrições mais detalhadas têm maior chance de serem aceitos.

| Métrica                               | Mediana MERGED | Mediana CLOSED |
|---------------------------------------|----------------|----------------|
| Comprimento da Descrição (Caracteres) | 830,00         | 862,00         |

Status de aceite vs. Descrição



Correlação [Comprimento da Descrição (Caracteres)]: sem correlação ( $p = 0,002$ ,  $p = 8,562e-001$  — sem significância estatística)


Discussão: Hipótese refutada: Nenhuma evidência estatística de que a descrição influencia o aceite.

### RQ04 — Status de aceite vs. Interações

Hipótese: PRs com mais interações (comentários/participantes) tendem a ser aceitos.

| Métrica       | Mediana MERGED | Mediana CLOSED |
|---------------|----------------|----------------|
| Comentários   | 2,00           | 3,00           |
| Participantes | 2,00           | 2,00           |

Status de aceite vs. Interações



**Correlação [Comentários]: fraca negativa ( $\rho = -0,152$ ,  $p < 0,001$ )**


↳ [Participantes]: sem correlação ( $\rho = 0,022$ ,  $p = 2,859e-002$ )

Discussão: Hipótese refutada: O coeficiente negativo indica que PRs com MAIS interações tendem a ser REJEITADOS. Isso ocorre pois PRs polêmicos ou com problemas severos de implementação naturalmente geram extensos debates antes de serem finalmente fechados em vez de mergeados rapidamente.

RQ05 — Revisões vs. Tamanho do PR

Hipótese: PRs maiores geram mais revisões, pois há mais código para revisar.

| Métrica                              | Med. Variável Indep. | Mediana Revisões |
|--------------------------------------|----------------------|------------------|
| Arquivos Alterados                   | 2,00                 | 1,00             |
| Total de Linhas (adições + remoções) | 32,00                | 1,00             |



Correlação [Arquivos Alterados]: fraca positiva ( $\rho = 0,220$ ,  $p < 0,001$ )


↳ [Total de Linhas (adições + remoções)]: fraca positiva ( $\rho = 0,260$ ,  $p < 0,001$ )

Discussão: Hipótese confirmada: Maior tamanho correlaciona com mais revisões.

RQ06 — Revisões vs. Tempo de análise

Hipótese: PRs com maior tempo de análise acumulam mais revisões.

| Métrica                  | Med. Variável Indep. | Mediana Revisões |
|--------------------------|----------------------|------------------|
| Tempo de Análise (Horas) | 16,28                | 1,00             |




Correlação [Tempo de Análise (Horas)]: fraca positiva ( $\rho = 0,158$ ,  $p < 0,001$ )

Discussão: Hipótese confirmada: Maior tempo correlaciona com mais revisões.

RQ07 — Revisões vs. Descrição

Hipótese: Descrições mais longas correlacionam com mais revisões (mais contexto → mais discussão).

| Métrica                               | Med. Variável Indep. | Mediana Revisões |
|---------------------------------------|----------------------|------------------|
| Comprimento da Descrição (Caracteres) | 837,00               | 1,00             |




Correlação [Comprimento da Descrição (Caracteres)]: fraca positiva ( $p = 0,175$ ,  $p < 0,001$ )

Discussão: Hipótese confirmada: Maior descrição correlaciona com mais revisões.

RQ08 — Revisões vs. Interações

Hipótese: PRs com mais participantes e comentários naturalmente têm mais revisões.

| Métrica       | Med. Variável Indep. | Mediana Revisões |
|---------------|----------------------|------------------|
| Comentários   | 2,00                 | 1,00             |
| Participantes | 2,00                 | 1,00             |



Correlação [Comentários]: moderada positiva ( $\rho = 0,496$ ,  $p < 0,001$ )

↳ [Participantes]: fraca positiva ( $\rho = 0,367$ ,  $p < 0,001$ )

Discussão: Hipótese confirmada: Mais interações correlacionam com mais revisões.

## 5. Sumarização global das métricas (processo)

Tabela com estatísticas descritivas (média, mediana e desvio padrão) sobre todo o dataset de PRs, no mesmo espírito do relatório do Laboratório 02 — visão agregada antes das correlações por RQ.

| Métrica                               | n      | Média    | Mediana | Desvio padrão |
|---------------------------------------|--------|----------|---------|---------------|
| Arquivos alterados                    | 10.333 | 18,56    | 2,00    | 250,37        |
| Total de linhas (adições + remoções)  | 10.333 | 2.271,57 | 32,00   | 46.336,34     |
| Tempo de análise (horas)              | 10.333 | 503,31   | 16,28   | 2.629,55      |
| Comprimento da descrição (caracteres) | 10.333 | 1.745,82 | 837,00  | 4.168,09      |
| Comentários                           | 10.333 | 3,63     | 2,00    | 6,40          |
| Participantes                         | 10.333 | 2,65     | 2,00    | 2,30          |
| Número de revisões                    | 10.333 | 2,61     | 1,00    | 4,30          |

### 5.1 Interpretação (processo):

Sumarização global (média, mediana e desvio padrão) sobre todos os PRs do dataset ( $n = 10.333$ ). O tempo de análise apresenta média 503,31 h e mediana 16,28 h (desvio 2.629,55 h;  $CV \approx 5,22$ ), compatível com distribuição fortemente assimétrica e cauda longa — poucos PRs tramitam muito tempo. O total de linhas (adições + remoções) tem mediana bem inferior à média (32,00 vs 2.271,57), típico de patches pequenos com exceções muito grandes. O número de revisões concentra-se em valores baixos (mediana 1,00), enquanto comentários e participantes mostram dispersão moderada (mediana de comentários 2,00), refletindo a maioria de PRs enxutos e um subconjunto com discussão intensa.

## 6. Discussão Geral e Conclusão

Analisando as 8 Questões de Pesquisa, observamos que 5 de 8 hipóteses foram confirmadas (RQ02, RQ05, RQ06, RQ07, RQ08) e apenas 3 foram refutadas (RQ01, RQ03, RQ04). Dentre os achados confirmados, o relacionamento de interações dita positivamente a cadência e número de revisões com a maior força do relatório (RQ08). Curiosamente, outras hipóteses formuladas apresentaram resultados inesperados: a RQ01 surpreendeu ao mostrar levemente que PRs MAIORES tendem a ser aceitos; a RQ03 não apresentou significância estatística ( $p\text{-valor} > 0,05$ ), evidenciando que o comprimento da descrição não influencia diretamente na aprovação; e a RQ04, embora estatisticamente significativa ( $p\text{-valor} < 0,05$ ), revelou uma correlação negativa, indicando que um maior volume de comentários está associado à rejeição do PR, possivelmente devido a discussões extensas geradas por códigos problemáticos antes de seu fechamento definitivo.

### Limitações do estudo e Trabalhos Futuros:

Observa-se que em variáveis como 'Review Count' a mediana massivamente se assenta em torno de 1,00, apontando que variabilidades altas acontecem fundamentalmente em PRs contendo grandes distorções, com as correlações em geral não ultrapassando a limitação de tendências fracas e moderadas. Para trabalhos futuros, sugere-se analisar isoladamente apenas PRs com `review_count`  $\geq 2$  para verificar se os padrões se mantêm ou fortalecem em revisões mais elaboradas.