

Laboratório 03 — Caracterizando a Atividade de Code Review no GitHub

Relatório Final · Lab03S03 · Análise, Visualização e Síntese

Engenharia de Software · Laboratório de Experimentação de Software · 6º Período · PUC Minas

Gerado em: 15/05/2026

Professor: Danilo de Quadros Maia Filho

Alunos: Sthel Felipe Torres e Vinicius Xavier Ramalho

Índice

1. Introdução	Pag. 2
1.1 Contexto	
1.2 Definição do Problema	
1.3 Questões de Pesquisa e Hipóteses	
1.4 Objetivo Principal	
2. Planejamento e execução do experimento	Pag. 3
2.1 Evidência visual do planejamento - Parte 2	
3. Metodologia	Pag. 5
3.1 Criação do Dataset	
3.2 Teste Estatístico	
3.3 Sumarização dos Resultados	
4. Resultados (RQs)	Pag. 6
• RQ01: Status de aceite vs. Tamanho do PR	Pag. 6
• RQ02: Status de aceite vs. Tempo de análise	Pag. 7
• RQ03: Status de aceite vs. Descrição	Pag. 8
• RQ04: Status de aceite vs. Interações	Pag. 9
• RQ05: Revisões vs. Tamanho do PR	Pag. 10
• RQ06: Revisões vs. Tempo de análise	Pag. 11
• RQ07: Revisões vs. Descrição	Pag. 12
• RQ08: Revisões vs. Interações	Pag. 13
5. Discussão Geral e Conclusão	Pag. 14

1. Introdução

A revisão de código (code review) é uma etapa indispensável no desenvolvimento de software, destacando-se em metodologias ágeis e projetos de código aberto (open source). Seu propósito é auditar modificações antes de incorporá-las à base principal do projeto, minimizando a inserção de falhas e elevando a qualidade do produto final. No ecossistema do GitHub, essa dinâmica ocorre primordialmente através de Pull Requests (PRs). Neles, as submissões são debatidas e julgadas por revisores, resultando em sua integração (MERGED) ou rejeição (CLOSED), frequentemente com o auxílio de checagens automatizadas. O presente laboratório tem como finalidade realizar uma caracterização empírica dessa prática em repositórios de destaque no GitHub. Para isso, investiga-se de que maneira fatores como tamanho da alteração, tempo de duração, riqueza da descrição e nível de interação afetam o desfecho do PR e a quantidade de revisões exigidas, evidenciando o impacto dessas variáveis no esforço analítico e na chance de aprovação.

1.1 Contexto

No GitHub, o PR atua como a unidade central para a análise de code review, pois congrega tanto as alterações técnicas quanto o histórico social do processo. Ele funciona, por um lado, como um "pacote de código" que deve ser validado quanto à sua exatidão e compatibilidade. Por outro, age como um fórum de negociação que registra comentários, exigências de correção, aprovações e o diálogo entre os envolvidos com diferentes atribuições.

A teoria e a prática indicam que os atributos do PR impactam diretamente a carga de trabalho da revisão e as chances de aceitação. Modificações extensas costumam exigir mais tempo de leitura e aumentam o risco de erros passarem despercebidos, enquanto envios menores tendem a ser assimilados rapidamente. O intervalo entre a abertura e o fechamento de um PR pode revelar tanto a sua complexidade técnica quanto a necessidade de muito retrabalho. Além disso, a qualidade da descrição dita o ritmo da revisão, pois esclarece motivações, limites, riscos e métodos de teste, facilitando ou travando o trabalho do revisor. Por fim, o volume de interações (como o número de participantes e comentários) aponta para processos mais colaborativos, rigorosos ou polêmicos, influenciando o sucesso da integração.

Como os repositórios populares variam drasticamente em termos de linguagem, governança, políticas de aceite e nível de automação, é crucial validar essas hipóteses intuitivas de forma empírica e em larga escala. Dessa forma, caracterizar o code review através de dados extraídos de PRs possibilita a identificação objetiva de padrões, gerando insights valiosos para colaboradores e mantenedores de projetos.

1.2 Definição do Problema

O foco deste experimento é investigar a relação entre as características observáveis dos PRs revisados e o desfecho do processo de revisão. De forma específica, analisa-se como as variáveis de tamanho, duração da análise, detalhamento da descrição e engajamento social determinam se um PR será efetivamente incorporado (MERGED) ou encerrado sem aprovação (CLOSED).

Para além do status final, o estudo também mede o impacto dessas mesmas características na intensidade da revisão, utilizando o total de revisões executadas no PR como métrica. Para garantir que os dados reflitam predominantemente o esforço humano — e para mitigar o viés de encerramentos automatizados —, o conjunto de dados foi filtrado para incluir exclusivamente PRs que possuam ao menos uma avaliação registrada e cujo tempo de vida (da abertura ao desfecho) ultrapasse uma hora.

1.3 Questões de Pesquisa e Hipóteses

Abaixo estão as perguntas que norteiam a pesquisa e as hipóteses informais elaboradas a partir das expectativas do comportamento em repositórios Java populares no GitHub.

- RQ01 (Tamanho vs Status): Estima-se que PRs com um volume massivo de modificações tenham menores chances de aprovação (MERGED). Alterações muito grandes sobrecarregam o revisor cognitivamente, elevam a probabilidade de falhas e complicam a análise de impacto, o que geralmente resulta em mais exigências de refatoração ou descarte.
- RQ02 (Tempo vs Status): PRs que demoram longos períodos em análise tendem a ser finalizados como CLOSED. Prazos extensos indicam atritos no processo, fazendo com que o código fique obsoleto frente à branch principal (envelhecimento do PR).
- RQ03 (Descrição vs Status): Textos descritivos mais robustos (maior body length) aumentam a probabilidade de um PR ser MERGED. Explicações minuciosas clarificam a intenção da mudança e métodos de teste, mitigando as dúvidas dos revisores.
- RQ04 (Interações vs Status): PRs com altos índices de comentários e participantes tendem a ser CLOSED. O alto engajamento frequentemente sinaliza polêmicas, identificação de falhas ou longos debates sobre arquitetura e estilo, gerando um desgaste que pode culminar na rejeição.
- RQ05 (Tamanho vs Revisões): Existe uma correlação positiva entre o tamanho do PR e a quantidade de revisões. Submissões extensas naturalmente demandam inspeções mais longas e são mais suscetíveis a apontamentos em diferentes módulos do código.
- RQ06 (Tempo vs Revisões): Quanto mais revisões um PR sofre, maior o seu tempo total de tramitação. Cada novo ciclo exige leitura, debate, codificação de correções e reexecução de testes automatizados (CI), alongando o período.
- RQ07 (Descrição vs Revisões): Antecipa-se uma correlação negativa, em que descrições mais ricas resultam em menos revisões. Quando a motivação e a lógica da mudança são bem expostas desde o princípio, o revisor tem menos dúvidas estruturais, encurtando rodadas de feedback.
- RQ08 (Interações vs Revisões): Prevê-se uma associação positiva entre as métricas de interação e a quantidade de revisões. Conversas e discussões densas geralmente geram a necessidade de ajustes complementares. Assim, o feedback resulta em novas validações formais.

1.4 Objetivo Principal

Realizar uma caracterização empírica da dinâmica de code review em repositórios de grande circulação no GitHub. O intuito é mapear como as métricas relativas a tamanho, duração temporal, qualidade do texto descritivo e engajamento social estão atreladas ao desfecho do processo e à quantidade de revisões recebidas. O fim último da pesquisa é extrair evidências quantitativas consistentes através da modelagem estatística de 10333 PRs.

2. Planejamento e execução do experimento

As figuras abaixo documentam o planejamento experimental (desenho inicial, etapas e organização da análise).


Etapa 1: Coleta de Repositórios



Etapa 2: Coleta de Pull Requests



2.1 Evidência visual do planejamento - Parte 2



3. Metodologia

3.1 Criação do Dataset

Os dados foram coletados via API GraphQL do GitHub. O dataset é composto pelos 10333 PRs que satisfazem todos os critérios abaixo:

- Repositórios: 200 repositórios mais populares do GitHub (ordenados por número de estrelas).
- Requisito mínimo por repositório: pelo menos 100 PRs com status MERGED ou CLOSED.
- Status do PR: apenas MERGED ou CLOSED (PRs abertos foram excluídos).
- Revisões: apenas PRs com pelo menos uma revisão registrada (campo `reviews.totalCount` ≥ 1).
- Filtro anti-bot: apenas PRs cujo intervalo entre a criação e o fechamento/merge é superior a 1 hora.

3.2 Teste Estatístico

Utilizamos o coeficiente de correlação de Spearman para todas as análises. A escolha é justificada pela natureza não-paramétrica dos dados: as métricas coletadas apresentam assimetria severa e outliers extremos, tornando a distribuição normal inviável e o teste de Pearson inadequado. O Spearman opera sobre postos (ranks), sendo robusto a essas distorções. Calculamos também o p-valor (aproximação t-Student bilateral) com limiar de significância $\alpha = 0,05$.

3.3 Sumarização dos Resultados


Para a Dimensão A (Status do PR), a variável dependente é binária (MERGED = 1, CLOSED = 0). A agregação dessas métricas é baseada nas correlações da população estatística gerada pelo Dataset completo de repositórios.

4. Resultados (RQs)

RQ01 — Status de aceite vs. Tamanho do PR

Hipótese: PRs menores (menos arquivos/linhas) têm maior chance de serem aceitos (MERGED).

Métrica	Mediana MERGED	Mediana CLOSED
Arquivos Alterados	2,00	1,00
Total de Linhas (adições + remoções)	34,00	28,00



Correlação [Arquivos Alterados]: fraca positiva ($\rho = 0,100$, $p < 0,001$)


↳ [Total de Linhas (adições + remoções)]: sem correlação ($\rho = 0,030$, $p = 2,321e-003$)

Discussão: Hipótese refutada: O coeficiente é positivo indicando que PRs maiores tendem a ser aceitos.

RQ02 — Status de aceite vs. Tempo de análise

Hipótese: PRs que levam mais tempo em análise tendem a ser rejeitados (CLOSED).

Métrica	Mediana MERGED	Mediana CLOSED
Tempo de Análise (Horas)	13,04	38,93




Correlação [Tempo de Análise (Horas)]: fraca negativa ($\rho = -0,139$, $p < 0,001$)

Discussão: Hipótese confirmada: Tempo longo se correlaciona com rejeição (coeficiente negativo).

RQ03 — Status de aceite vs. Descrição

Hipótese: PRs com descrições mais detalhadas têm maior chance de serem aceitos.

Métrica	Mediana MERGED	Mediana CLOSED
Comprimento da Descrição (Caracteres)	830,00	862,00




Correlação [Comprimento da Descrição (Caracteres)]: sem correlação ($p = 0,002$, $p = 8,562e-001$ — sem significância estatística)

Discussão: Hipótese refutada: Nenhuma evidência estatística de que a descrição influencia o aceite.

RQ04 — Status de aceite vs. Interações

Hipótese: PRs com mais interações (comentários/participantes) tendem a ser aceitos.

Métrica	Mediana MERGED	Mediana CLOSED
Comentários	2,00	3,00
Participantes	2,00	2,00



Correlação [Comentários]: fraca negativa ($\rho = -0,152$, $p < 0,001$)


↳ [Participantes]: sem correlação ($\rho = 0,022$, $p = 2,859e-002$)

Discussão: Hipótese refutada: O coeficiente negativo indica que PRs com MAIS interações tendem a ser REJEITADOS. Isso ocorre pois PRs polêmicos ou com problemas severos de implementação naturalmente geram extensos debates antes de serem finalmente fechados em vez de mergeados rapidamente.

RQ05 — Revisões vs. Tamanho do PR

Hipótese: PRs maiores geram mais revisões, pois há mais código para revisar.

Métrica	Med. Variável Indep.	Mediana Revisões
Arquivos Alterados	2,00	1,00
Total de Linhas (adições + remoções)	32,00	1,00



Correlação [Arquivos Alterados]: fraca positiva ($\rho = 0,220$, $p < 0,001$)


↳ [Total de Linhas (adições + remoções)]: fraca positiva ($\rho = 0,260$, $p < 0,001$)

Discussão: Hipótese confirmada: Maior tamanho correlaciona com mais revisões.

RQ06 — Revisões vs. Tempo de análise

Hipótese: PRs com maior tempo de análise acumulam mais revisões.

Métrica	Med. Variável Indep.	Mediana Revisões
Tempo de Análise (Horas)	16,28	1,00




Correlação [Tempo de Análise (Horas)]: fraca positiva ($\rho = 0,158$, $p < 0,001$)

Discussão: Hipótese confirmada: Maior tempo correlaciona com mais revisões.

RQ07 — Revisões vs. Descrição

Hipótese: Descrições mais longas correlacionam com mais revisões (mais contexto → mais discussão).

Métrica	Med. Variável Indep.	Mediana Revisões
Comprimento da Descrição (Caracteres)	837,00	1,00




Correlação [Comprimento da Descrição (Caracteres)]: fraca positiva ($p = 0,175$, $p < 0,001$)

Discussão: Hipótese confirmada: Maior descrição correlaciona com mais revisões.

RQ08 — Revisões vs. Interações

Hipótese: PRs com mais participantes e comentários naturalmente têm mais revisões.

Métrica	Med. Variável Indep.	Mediana Revisões
Comentários	2,00	1,00
Participantes	2,00	1,00



Correlação [Comentários]: moderada positiva ($\rho = 0,496$, $p < 0,001$)

↳ [Participantes]: fraca positiva ($\rho = 0,367$, $p < 0,001$)

Discussão: Hipótese confirmada: Mais interações correlacionam com mais revisões.

5. Discussão Geral e Conclusão

Analisando as 8 Questões de Pesquisa, observamos que 5 de 8 hipóteses foram confirmadas (RQ02, RQ05, RQ06, RQ07, RQ08) e apenas 3 foram refutadas (RQ01, RQ03, RQ04). Dentre os achados confirmados, o relacionamento de interações dita positivamente a cadência e número de revisões com a maior força do relatório (RQ08). Curiosamente, outras hipóteses formuladas apresentaram resultados inesperados: a RQ01 surpreendeu ao mostrar levemente que PRs MAIORES tendem a ser aceitos; a RQ03 não apresentou significância estatística ($p\text{-valor} > 0,05$), evidenciando que o comprimento da descrição não influencia diretamente na aprovação; e a RQ04, embora estatisticamente significativa ($p\text{-valor} < 0,05$), revelou uma correlação negativa, indicando que um maior volume de comentários está associado à rejeição do PR, possivelmente devido a discussões extensas geradas por códigos problemáticos antes de seu fechamento definitivo.

Limitações do estudo e Trabalhos Futuros:

Observa-se que em variáveis como 'Review Count' a mediana massivamente se assenta em torno de 1,00, apontando que variabilidades altas acontecem fundamentalmente em PRs contendo grandes distorções, com as correlações em geral não ultrapassando a limitação de tendências fracas e moderadas. Para trabalhos futuros, sugere-se analisar isoladamente apenas PRs com `review_count` ≥ 2 para verificar se os padrões se mantêm ou fortalecem em revisões mais elaboradas.